



SEEDS

Tools for Statistical Data Science

DATA PROCESS

1. ตรวจสอบข้อมูลเบื้องต้น (Initial Data Exploration)
2. กำหนดวัตถุประสงค์ของโปรเจกต์ (Define Objective)
3. ตรวจสอบการกระจายของข้อมูล (Data Distribution Analysis)
4. Data Preparation & Manipulation
5. Train / Test Model
6. ประเมินประสิทธิภาพของโมเดล (Model Evaluation)
7. ตรวจสอบ Outlier (Outlier Detection)
8. สรุปผล (Conclusion)

DATASET



Dataset: Seeds Dataset



Samples: 210 samples



Features: 7 features




3 Classes (Kama, Rosa, Canadian)



FEATURES

1. **Area A:** พื้นที่ของเมล็ดในภาพ 2D
2. **Perimeter P:** ความยาวรอบขอบเขตของเมล็ด
3. **Compactness C:** รูปร่างของเมล็ดที่ใกล้เคียงกับรูปวงกลม
4. **Length of kernel:** ความยาวเมล็ด
5. **Width of kernel:** ความกว้างเมล็ด
6. **Asymmetry coefficient:** ความเอียงหรือเบี้ยวของเมล็ดจากแกนกลาง
7. **Length of kernel groove:** ความยาวของร่องกลางเมล็ด (crease/groove)


FEATURE DISTRIBUTION



- วิเคราะห์ความสัมพันธ์ระหว่างตัวแปรแต่ละคู่
- พบว่า feature บางตัวสามารถแยก class ได้ชัดเจน
- มีความสัมพันธ์เชิงเส้นสูงในหลายตัวแปร




CORRELATION MATRIX



จากตาราง Correlation Matrix พบว่า Area, Perimeter, Kernel length, Kernel width มีความสัมพันธ์เชิงสูงมาก (Correlation > 0.90)

DISTRIBUTION PLOTS




จาก Grouped Normal Distribution ที่ผ่านการ Standardized มาแล้วสรุปผลได้ว่า
Class 1 (สีเขียว): มีขนาดอยู่กึ่งกลางระหว่าง 2 และ 3

Class 2 (สีส้ม): เป็นเมล็ดพืชที่มีขนาดใหญ่ที่สุดในทุกมิติ (พื้นที่, ความกว้าง, ความยาว) และมีร่องเมล็ด (Groove) ยาวที่สุด

Class 3 (สีน้ำเงิน): เป็นเมล็ดพืชที่มีขนาดเล็กที่สุด โดยเฉพาะพื้นที่และเส้นรอบวง




COVARIANCE MATRIX



ตรวจสอบ Covariance Matrix ของทั้ง 3 คลาส
พบว่า มี Pattern ที่ใกล้เคียงกัน

GAUSSIAN DISTRIBUTION



ผลลัพธ์จากการทดสอบ โดยใช้ Shapiro-Wilk (p-value) พบว่ามีบาง Features ในชุดข้อมูล Training ไม่เป็นรูประฆังคว่ำ

- **Class 1:** Asymmetry_Coeff = 0.0115
- **Class 2:** Area A = 0.0463
- **Class 3:** Kernel_Width = 0.0485

ซึ่งเราจะปรับโดยใช้ PowerTransformation เพื่อปรับให้ข้อมูลบางอันมีการแจกแจงแบบ Normal (ตามเงื่อนไขของ LDA)




OBJECTIVE

เพื่อพัฒนาโมเดลสำหรับจำแนกคลาสของเมล็ด
พืชที่มีจำนวนคลาสทั้งหมด 3 คลาส


TECHNIQUE

LDA Classifier

- นำข้อมูลที่ผ่านการลดมิติด้วย LDA มาใช้ในการสร้างโมเดลจำแนกประเภทข้อมูล
- อาศัยสมมติฐานการกระจายตัวแบบ Gaussian ในการสร้างเส้นแบ่งเชิงเส้นระหว่างคลาส
- ช่วยเพิ่มความชัดเจนในการแยกกลุ่มข้อมูล และลดความซับซ้อนของตัวแปร (features)
- เพิ่มประสิทธิภาพและความแม่นยำในการจำแนกประเภทข้อมูล



One-versus-all Discriminant Axes for 4 classes in 3d




WHY LDA



Classification

ต้องการทำ Model เพื่อ
จำแนกคลาสของข้อมูล
มากกว่า 2 คลาส อย่างมี
ประสิทธิภาพ



Low-Dimensionality

LDA จัดการกับ
Multicollinearity ได้ดี
และมีคุณสมบัติ
Dimensional Reduction




Feature Insights

สามารถอธิบายได้ว่า
Feature ไหนมีอิทธิพลต่อ
การแยกสายพันธุ์มากที่สุด




ANALYSIS & MODELING

LDA (LINEAR DISCRIMINANT ANALYSIS)




LDA

ใช้ลดมิติและแยกกลุ่มข้อมูลโดย class label เพื่อให้การจำแนกประเภทข้อมูลให้ชัดเจนมากขึ้น



Gaussian Distribution

รูปแบบการกระจายตัวของข้อมูล ที่เหมาะสมต่อการทำงานกับ LDA



Test/ Identifying outlier

ตรวจสอบ Outlier เพื่อสังเกตข้อมูลที่อาจส่งผลต่อความแม่นยำของการวิเคราะห์และโมเดล



MODEL PERFORMANCE


Accuracy อยู่ที่

95%


Macro avg = 0.95

Weighted avg = 0.95

โมเดลไม่ได้ลำเอียงไปที่
คลาสใดคลาสหนึ่ง




RESULT



สังเกตว่ากลุ่มจุดสีแต่ละสีมีการเกาะ
กลุ่มกัน และไม่ค่อยซ้อนทับกัน





OUTLIER DETECTION



พบค่าผิดปกติ (OUTLIER DETECTION) ในกลุ่มข้อมูลที่ 1 และ 3 ซึ่งมีค่าพิกัดบนแกน LD1 และ LD2 แยกห่างจาก ศูนย์กลางของกลุ่ม (CENTROID) อย่างเห็นได้ชัด



FEATURE IMPORTANCE



ขนาดของพื้นที่ Area A คือปัจจัยหลัก
ที่ใช้แยก Class Rosa ออกจากกลุ่ม

ความยาวของร่องกลางเมล็ด คือปัจจัย
หลักที่ใช้แยก Kama และ Canadian
ที่พื้นที่ใกล้เคียงกัน

MEMBER

นายวิชวิทย์ นัฏตรีพงษ์ 6604053630359

นายไพรัช เกิดชูชื่น 6604053610102

นายสนรยา เอี่ยมจรัส 6604053610391

นายธนวิษฐ์ เรืองเมือง 6604053620175

นางสาวนภัสสร มีปิ่น 6604053620078

นางสาวสิริธร เค้าแดง 6604053630464

นางสาวจิตาภา เวชพราหมณ์ 6604053620043

